

Capítulo 3

Métodos iterativos para resolución de sistemas de ecuaciones lineales

Introducción

Los métodos directos vistos anteriormente tienen una desventaja desde el punto de vista de la cantidad de operaciones que involucra el proceso de eliminación. El orden de la cantidad de operaciones es $O(n^3)$, y a esto se debe sumar las operaciones de las sustituciones para obtener la solución final ($O(n^2)$). Entonces, el costo computacional crece bastante cuando el número de ecuaciones es grande ¹.

Para sistemas con un número importante de ecuaciones se utilizan por lo general los *métodos iterativos*. Estos métodos se caracterizan por construir una sucesión de soluciones $\{x^{(k)}\}_{k=1}^{\infty}$ que se aproxima a la solución exacta. Esta sucesión se obtiene partiendo de un vector inicial $x^{(0)}$, y una *fórmula de recurrencia* para obtener los siguientes elementos de la sucesión.

3.1. Algunos conceptos de álgebra lineal

Antes de ver los métodos numéricos iterativos para resolución de sistemas de ecuaciones lineales, se repasarán algunos conceptos importantes del álgebra lineal. Si bien se podría generalizar para cualquier espacio vectorial V , se restringe sólo al espacio $\mathbb{R}^n$ que representará el espacio de vectores columna de n componentes. Así, si $x \in \mathbb{R}^n$, se representará en componentes como $x = (x_1, x_2, \dots, x_n)^t$ cuando se escriba en una línea.

3.1.1. Normas Vectoriales

Definición 3.1. Una **norma vectorial** en $\mathbb{R}^n$ es una función $\|\cdot\|$ de $\mathbb{R}^n$ en $\mathbb{R}$, con las siguientes propiedades:

i) $\|x\| \geq 0$ para todo $x \in \mathbb{R}^n$

ii) $\|x\| = 0$ si y sólo si $x = \mathbf{0}$

¹Para mayor detalle de este tema, puede profundizar en Burden, R. L. y Faires, J. D. *Análisis numérico*, 7ma edición. International Thomson Editores, 2002.

iii) $\|\lambda x\| = |\lambda| \|x\|$ para todo $\lambda \in \mathbb{R}$ y $x \in \mathbb{R}^n$

iv) $\|x + y\| \leq \|x\| + \|y\|$ para todo $x, y \in \mathbb{R}^n$

La norma vectorial es una noción del *medida*, de tamaño de un vector. En la siguiente tabla se muestran ejemplos de 3 normas comunes que podemos encontrar en la bibliografía. Las dos primeras son las que más se utilizarán a lo largo de este texto.







Norma	Bola unitaria en $\mathbb{R}^2$	Bola unitaria en $\mathbb{R}^3$
$\ x\ _2 = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}$		
$\ x\ _\infty = \max_{1 \leq i \leq n} x_i $		
$\ x\ _1 = \sum_{i=1}^n x_i $		

Tabla 3.1: Bolas unitarias $\mathcal{B}_p = \{x \in \mathbb{R}^n : \|x\|_p \leq 1\}$ para las normas $p = 1, 2, \infty$.

En la Tabla 3.1 podemos ver las definiciones de diferentes normas, con sus *bolas unitarias*. Lo sombreado representa todos los puntos del espacio en cuestión ($\mathbb{R}^2$ ó $\mathbb{R}^3$) tal que $\|x\| \leq 1$. Se puede apreciar que cada vector perteneciente al espacio vectorial puede tener *diferente tamaño* según la norma que elegimos para *medirlo*.

Ejemplo 1. Si tomamos $x = (1, 1)^t \in \mathbb{R}^2$, tenemos que $\|x\|_2 = \sqrt{2}$, mientras que $\|x\|_\infty = 1$ y $\|x\|_1 = 2$.

Un resultado importante muy útil relacionado a la norma $\|\cdot\|_2$ es la **desigualdad de Cauchy-Bunyakovsky-Schwarz**:

Teorema 3.1. Para cada $x = (x_1, x_2, \dots, x_n)^t$ y $y = (y_1, y_2, \dots, y_n)^t$ en $\mathbb{R}^n$,

$$x^t y \leq \|x\|_2 \|y\|_2$$

La norma de un vector proporciona la idea de distancia entre el vector y el origen. De igual manera, la **distancia entre dos vectores** se define como la norma de la diferencia entre ellos. Este concepto es muy importante a la hora de determinar el error entre soluciones. La siguiente definición muestra el ejemplo relacionado a las normas $\|\cdot\|_2$ y $\|\cdot\|_\infty$.

Definición 3.2. Si $x = (x_1, x_2, \dots, x_n)^t$ y $y = (y_1, y_2, \dots, y_n)^t$ son vectores en $\mathbb{R}^n$, las distancias en las normas $\|\cdot\|_2$ y $\|\cdot\|_\infty$ se definen como:

$$\|x - y\|_2 = \left(\sum_{i=1}^n (x_i - y_i)^2 \right)^{1/2} \quad \text{y} \quad \|x - y\|_\infty = \max_{1 \leq i \leq n} |x_i - y_i|$$

Relacionado a este concepto de distancia, se define el siguiente concepto de convergencia (ver Definición 1.8):

Definición 3.3. La sucesión de vectores $\{x^{(k)}\}_{k=1}^\infty$ en $\mathbb{R}^n$ **converge** al vector x respecto de la norma $\|\cdot\|$ si, dado $\epsilon > 0$, existe un entero $N(\epsilon)$ tal que

$$\|x^{(k)} - x\| < \epsilon \quad \text{para toda} \quad k \geq N(\epsilon)$$

.

3.1.2. Normas matriciales

Así como se define la noción de distancia entre vectores en relación al concepto de norma vectorial, en esta sección se introduce el concepto de distancia y norma matriciales.

Definición 3.4. Una **norma matricial** en $\mathbb{R}^{n \times n}$ es una función $\|\cdot\|$ de valor real que cumple las siguientes propiedades, para todas las matrices A y B en $\mathbb{R}^{n \times n}$ y λ real:

- i) $\|A\| \geq 0$
- ii) $\|A\| = 0$ si y sólo si $A = \mathbf{O}$, con $\mathbf{O}$ la matriz nula de $\mathbb{R}^{n \times n}$
- iii) $\|\lambda A\| = |\lambda| \|A\|$
- iv) $\|A + B\| \leq \|A\| + \|B\|$
- v) $\|AB\| \leq \|A\| \|B\|$

Luego, la **distancia entre matrices** A y B de tamaño $n \times n$ se define como $\|A - B\|$.

Hay diferentes formas de obtener o definir normas matriciales. Las que se tratarán en este texto son aquellas asociadas o definidas a partir de normas vectoriales. Para ello, se puede demostrar el siguiente resultado:

Teorema 3.2. Si $\|\cdot\|$ es una norma vectorial en $\mathbb{R}^n$,

$$\|A\| = \max_{\|x\|=1} \|Ax\|$$

en una norma matricial.

Estas normas definidas a partir de normas vectoriales, reciben el nombre de **normas matriciales naturales** o *inducidas*, asociadas a la norma del vector.

Como consecuencia podemos obtener:

Corolario 3.3. Para cualquier vector $z \in \mathbb{R}^n$ no nulo, matriz $A \in \mathbb{R}^{n \times n}$, y cualquier norma natural $\|\cdot\|$,

$$\|Az\| \leq \|A\| \|z\|$$

Como ejemplo de estas normas, se puede demostrar el siguiente resultado:

Teorema 3.4. Si $A = (a_{ij})$ es una matriz en $\mathbb{R}^{n \times n}$, entonces $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$.

A continuación se verán algunos conceptos importantes que nos ayudarán al análisis de los métodos iterativos. También se proporcionará una forma simple para determinar la norma $\|\cdot\|_2$ de una matriz.

3.1.3. Autovalores y autovectores: radio espectral

Definición 3.5. Si A es una matriz cuadrada, el **polinomio característico** de A se define como:

$$p(\lambda) = \det(A - \lambda I)$$

Si la matriz A es de tamaño $n \times n$, su polinomio característico es de grado n , lo que proporciona n raíces (reales o complejas y no necesariamente diferentes) que serán de nuestro interés.

Definición 3.6. Las raíces o ceros del polinomio característico p de una matriz A se denominan **autovalores** de la matriz A . Si λ es un autovalor de la matriz A , y el vector x no nulo es solución de $(A - \lambda I)x = \mathbf{0}$, entonces x se denomina **autovector** de A asociado al autovalor λ .

Si x es un autovector de la matriz A asociado a un autovalor λ , cualquier múltiplo de x también lo será. Por lo tanto, comúnmente se utiliza como representante de autovector asociado al autovector de norma unitaria. Por lo tanto *para todos los autovalores y cualquier norma vectorial, existen autovectores de norma 1.*

Definición 3.7. El **radio espectral** $\rho(A)$ de una matriz A se define como:

$$\rho(A) = \max \{|\lambda|, \text{ con } \lambda \text{ autovalor de } A\}$$

Para el caso λ real, se considera valor absoluto, mientras que para λ complejo, se toma el módulo del mismo.

Un resultado importante es el siguiente teorema:

Teorema 3.5. Si $A \in \mathbb{R}^{n \times n}$,

$$1) \|A\|_2 = [\rho(A^t A)]^{1/2}$$

$$2) \rho(A) \leq \|A\| \text{ para cualquier norma natural } \|\cdot\|$$

Demostración. Demostraremos el punto 2), ya que para demostrar 1) se deben introducir conceptos que están fuera del alcance de este texto.

Para probar 2), si λ es un autovalor de A , con autovector x tal que $\|x\| = 1$ para alguna norma vectorial, utilizando las propiedades de las definiciones de normas tenemos:

$$|\lambda| = |\lambda| \|x\| = \|\lambda x\| = \|Ax\| \leq \|A\| \|x\| = \|A\|$$

Por lo tanto

$$\rho(A) = \max |\lambda| \leq \|A\|$$

para la norma matricial natural asociada a la norma vectorial arbitraria. ■

Como consecuencia del punto 1), si A es simétrica, $\|A\|_2 = \rho(A)$.

Definición 3.8. Una matriz cuadrada A se dice **convergente** si

$$\lim_{k \rightarrow \infty} (A^k)_{ij} = 0 \quad \text{para cada } i = 1, 2, \dots, n \text{ y } j = 1, 2, \dots, n$$

Para la definición anterior, se tienen las siguientes equivalencias, muy útiles al momento de analizar los métodos numéricos:

Teorema 3.6. Las siguientes afirmaciones son equivalentes:

- i) A es una matriz convergente
- ii) $\lim_{k \rightarrow \infty} \|A^k\| = 0$ para alguna norma matricial
- iii) $\lim_{k \rightarrow \infty} \|A^k\| = 0$ para todas las normas matriciales
- iv) $\rho(A) < 1$
- v) $\lim_{k \rightarrow \infty} A^k x = \mathbf{0}$, para cada x

De estas equivalencias, se puede afirmar o usar como definición alternativa, que una matriz es convergente si y sólo si su radio espectral es menor a 1.

3.2. Métodos iterativos clásicos

Los métodos iterativos clásicos convierten al sistema $Ax = b$ en un sistema equivalente $x = Tx + c$ para una matriz fija T y un vector fijo c . A partir de este nuevo sistema se construye una fórmula de recurrencia que converja a la solución del mismo, y por lo tanto, resuelve el sistema original $Ax = b$.

La fórmula de recurrencia propuesta es la siguiente:

$$x^{(k+1)} = Tx^{(k)} + c. \quad (3.1)$$

Luego, dado un vector inicial $x^{(0)}$ se construye una sucesión de soluciones $\{x^{(k)}\}_{k=1}^{\infty}$ por medio de la Ecuación 3.1 con el objetivo de que dicha sucesión converja a la solución del sistema $Ax = b$.

3.2.1. Método de Jacobi

Este método consiste en resolver (*despejar*) x_i de la i -ésima ecuación de $Ax = b$. Es decir:

$$x_i^{(k+1)} = \left[b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right] / a_{ii} \quad (3.2)$$

Para poder expresar este método en forma matricial como en la Ec.(3.1), vamos a descomponer $A = L + D + U$, donde D es la matriz diagonal de A , L la parte estrictamente triangular inferior de A , y U es la parte estrictamente triangular superior de A . De esta manera, el sistema $Ax = b$ se puede escribir como $(L + D + U)x = b$. Si D^{-1} existe, es decir, $a_{ii} \neq 0$ para cada i , tenemos

$$x = -D^{-1}(L + U)x + D^{-1}b \quad (3.3)$$

como sistema equivalente a $Ax = b$. Si llamamos $T_j = -D^{-1}(L + U)$ y $c_j = D^{-1}b$, tenemos el esquema iterativo (3.1) que representa las operaciones (3.2):

$$x^{(k+1)} = T_j x^{(k)} + c_j. \quad (3.4)$$

El algoritmo en Octave de este método se transcribe a continuación:

```
function [x,it,r_h]=jacobi(A,b,x0,maxit,tol)
n=length(b);it=0;r_h=[];x=x0;
while (it<maxit)
    it+=1;
    for i=1:n
        x(i) = (b(i)-A(i,1:i-1)*x0(1:i-1)-A(i,i+1:n)*x0(i+1:n))...
            /A(i,i);
    endfor
    err=norm(x-x0,inf)/norm(x,inf);
    r_h=[r_h;err];
    if(err<tol)
        break;
    endif
    x0=x;
endwhile
if it==maxit
    disp('Se ha llegado al Nro maximo de iteraciones')
endif
```

Observación 10. El alumno deberá analizar cada línea del código para entender el algoritmo. De esta manera podrá introducir los cambios necesarios, según se soliciten en los ejercicios a resolver.

3.2.2. Método de Gauss-Seidel

Una posible *mejora* al método de Jacobi se puede pensar a partir de la Ec. (3.2). Si calculamos cada $x_i^{(k+1)}$ en orden creciente de i , podríamos *usar* las componentes ya calculadas menores a i de la iteración $k+1$ en lugar de usar todas las componentes de la iteración k . Es decir:

$$x_i^{(k+1)} = \left[b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right] / a_{ii} \quad (3.5)$$

Este método se conoce como Método de Gauss-Seidel. Si lo queremos expresar de forma matricial, utilizamos la misma descomposición de A que en el método anterior, pero ahora construimos el sistema equivalente como $(D + L)x = -Ux + b$. Por lo tanto, si $(D + L)^{-1}$ existe, tenemos el esquema iterativo matricial:

$$x^{(k+1)} = T_g x^{(k)} + c_g. \quad (3.6)$$

donde $T_g = -(D + L)^{-1}U$ y $c_g = (D + L)^{-1}b$.

El algoritmo en Octave del método de Gauss-Seidel es el siguiente:

```
function [x,it,r_h]=gauss_seidel(A,b,x0,maxit,tol)
n=length(b);it=0;r_h=[];x=x0;
while (it<maxit)
    it+=1;
    for i=1:n
        x(i) = (b(i)-A(i,1:i-1)*x(1:i-1)-A(i,i+1:n)*x0(i+1:n))...
            /A(i,i);
    endfor
    err=norm(x-x0,inf)/norm(x,inf);
    r_h=[r_h;err];
    if(err<tol)
        break;
    endif
    x0=x;
endwhile
if it==maxit
    disp('Se ha llegado al Nro maximo de iteraciones')
endif
```

Observación 11. En el algoritmo anterior se puede identificar la similitud con el método de Jacobi. Al igual que el caso anterior, el alumno debe estar en condiciones de identificar las diferencias y cambiar el algoritmo en caso de ser necesario.

Observación 12. En ambos algoritmos, se implementan las fórmulas 3.2 y 3.5. Pero si queremos analizar de forma teórica los métodos para estudiar su convergencia y comportamiento iterativo, se usan las expresiones matriciales asociadas.

3.2.3. Convergencia de los métodos iterativos

Se presentan a continuación, algunos resultados que garantizan la convergencia de los métodos iterativos vistos anteriormente.

El siguiente es un resultado general para cualquier método iterativo que responde a la fórmula de recurrencia (3.1).

Teorema 3.7. *La sucesión $\{x^{(k)}\}_{k=1}^{\infty}$ definida por $x^{(k+1)} = Tx^{(k)} + c$ converge a la solución del sistema $x = Tx + c$ para cualquier vector inicial $x^{(0)}$ si, y sólo si $\rho(T) < 1$.*

La demostración no es compleja, por lo que el alumno puede sin problemas seguirla en la bibliografía recomendada.²

Calcular las matrices de iteración (para obtener su radio espectral) puede ser costoso, ya que en la práctica, no se utilizan, si no que se realizan los algoritmos a partir de las expresiones de cada componente de los vectores soluciones como (3.2) y (3.5). Pero para casos particulares de matrices A del sistema, podemos encontrar condiciones suficientes para garantizar convergencia.

Teorema 3.8. *Si la matriz A es estrictamente diagonal dominante, entonces, para cualquier vector inicial $x^{(0)}$, los métodos de Jacobi y Gauss-Seidel convergen a la solución del sistema $Ax = b$.*

También se puede demostrar que si la matriz A es simétrica y definida positiva, el método de Gauss-Seidel converge a la solución del sistema $Ax = b$ para cualquier vector inicial $x^{(0)}$.

3.3. Método de Relajación Sucesiva (SOR)

El método de **Relajación Sucesiva** (*Successive Over-Relaxation*, SOR) es una generalización del método de Gauss-Seidel que introduce un parámetro $\omega > 0$ llamado **parámetro de relajación**, con el objetivo de acelerar la convergencia.

La idea es combinar la iteración de Gauss-Seidel con el valor actual $x_i^{(k)}$, ponderando ambos mediante ω . Dado el valor que produciría Gauss-Seidel:

$$x_i^{\text{GS}} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right),$$

la actualización de SOR se define como:

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \omega x_i^{\text{GS}}, \quad i = 1, \dots, n. \quad (3.7)$$

Es decir, $x_i^{(k+1)}$ es una combinación convexa (cuando $0 < \omega < 2$) entre el valor actual y el valor sugerido por Gauss-Seidel.

Usando la descomposición $A = L + D + U$, la iteración SOR puede escribirse como:

$$(D + \omega L) x^{(k+1)} = [(1 - \omega)D - \omega U] x^{(k)} + \omega b,$$

lo que corresponde a la forma canónica $x^{(k+1)} = T_{\omega} x^{(k)} + c_{\omega}$ con:

$$T_{\omega} = (D + \omega L)^{-1} [(1 - \omega)D - \omega U], \quad c_{\omega} = \omega (D + \omega L)^{-1} b.$$

²Una demostración completa se puede ver en Burden, R. L. y Faires, J. D. *Análisis numérico*, 7ma edición. International Thomson Editores, 2002.

3.3.1. Casos particulares y rol del parámetro ω

El parámetro ω controla cuánto se “mueve” la iteración en la dirección sugerida por Gauss-Seidel. Para $\omega = 1$, la fórmula (3.7) se reduce exactamente al método de Gauss-Seidel, por lo que SOR puede verse como una familia de métodos parametrizada por ω que contiene a Gauss-Seidel como caso particular.

Cuando $0 < \omega < 1$ se habla de **subrelajación**: cada actualización avanza menos que lo que indicaría Gauss-Seidel, lo que puede ser útil para estabilizar la iteración cuando Gauss-Seidel oscila o diverge. Cuando $1 < \omega < 2$ se habla de **sobrerelajación**: cada actualización “extrapola” más allá del valor de Gauss-Seidel, apostando a que la corrección apunta en la dirección correcta. Este es el caso de mayor interés práctico, pues un ω bien elegido puede reducir significativamente el número de iteraciones respecto a Gauss-Seidel.

3.3.2. Convergencia del método

Proposición 3.9. *Para que el método SOR converja, es necesario que $0 < \omega < 2$.*

Esquema de demostración. Puede mostrarse que el radio espectral de T_ω satisface $\rho(T_\omega) \geq |\omega - 1|$. Si $\omega \notin (0, 2)$, entonces $\rho(T_\omega) \geq 1$ y la convergencia no puede garantizarse. ■

Teorema 3.10 (Teorema de Ostrowski-Reich). *Si A es simétrica definida positiva, entonces el método SOR converge para todo $\omega \in (0, 2)$.*

El método converge si y sólo si $\rho(T_\omega) < 1$, en cuyo caso la velocidad de convergencia mejora o empeora respecto a Gauss-Seidel según la elección de ω .

3.3.3. Elección del parámetro de relajación

En general, determinar el ω óptimo es un problema difícil que depende de las propiedades espectrales de A . Se distinguen dos situaciones.

Existe un caso particular para encontrar una fórmula explícita para el parámetro óptimo en términos del radio espectral $\rho(T_j)$ de la matriz de iteración de Jacobi.³

Teorema 3.11. *Si A es definida positiva y tridiagonal, entonces $\rho(T_g) = [\rho(T_j)]^2 < 1$ y el ω óptimo para el método de SOR es*

$$\omega = \frac{2}{1 + \sqrt{1 - [\rho(T_j)]^2}}$$

y para este ω , se tiene $\rho(T_\omega) = \omega - 1$.

Estimación numérica de ω . Cuando A no satisface las hipótesis anteriores, no existe una fórmula cerrada para ω y se recurre a estrategias numéricas. La más utilizada en la práctica es la **búsqueda experimental**: se ejecutan unas pocas iteraciones (típicamente entre 10 y 20) para varios valores de ω en una malla gruesa del intervalo $(1, 2)$, se estima

³El resultado se extiende a la clase más amplia de matrices *consistentemente ordenadas* con autovectores reales de T_j , noción introducida por Young (Young, David M., *Iterative methods for solving partial difference equations of elliptic type*, Transactions of the American Mathematical Society, Vol.76). Las matrices tridiagonales son el caso particular más común de esta clase.

la tasa de convergencia de cada uno — por ejemplo, mediante el cociente $\|x^{(k+1)} - x^{(k)}\|/\|x^{(k)} - x^{(k-1)}\|$ — y se selecciona el ω que produce la reducción más rápida. Una variante más sofisticada consiste en estimar $\rho(T_\omega)$ a partir de los residuos observados y actualizar ω durante la propia iteración (*SOR adaptativo*), aunque su implementación es más delicada. En cualquier caso, la sensibilidad de SOR respecto a ω es un aspecto que no debe subestimarse: un valor inadecuado puede ser peor que Gauss-Seidel, mientras que un valor cercano al óptimo puede reducir el número de iteraciones en uno o dos órdenes de magnitud.

3.4. Criterios de parada

En los métodos iterativos estudiados se construye una sucesión $\{x^{(k)}\}$ que, bajo las condiciones de convergencia analizadas, tiende a la solución exacta x^* del sistema $Ax = b$. En la práctica es necesario detener el proceso en alguna iteración finita k , por lo que se requiere un criterio que indique cuándo la aproximación obtenida es suficientemente buena.

Para la iteración k se definen tres cantidades de interés: el **error** $e^{(k)} = x^{(k)} - x^*$, el **residuo** $r^{(k)} = b - Ax^{(k)}$, y el **incremento** $\delta^{(k)} = x^{(k+1)} - x^{(k)}$.

El error y el residuo están vinculados por la relación

$$Ae^{(k)} = r^{(k)}, \quad (3.8)$$

de modo que cuando el error tiende a cero, el residuo también lo hace, y viceversa (siempre que A sea no singular).

3.4.1. Acotación del error mediante el incremento

A partir de las definiciones anteriores se tiene:

$$e^{(k+1)} = x^{(k+1)} - x^* = e^{(k)} + \delta^{(k)},$$

de donde $e^{(k)} = e^{(k+1)} - \delta^{(k)}$. Aplicando la desigualdad triangular y la relación del método iterativo convergente $\|e^{(k+1)}\| \leq \|T\| \|e^{(k)}\|$:

$$\|e^{(k)}\| = \|e^{(k+1)} - \delta^{(k)}\| \leq \|e^{(k+1)}\| + \|\delta^{(k)}\| \leq \|T\| \|e^{(k)}\| + \|\delta^{(k)}\|.$$

Para matrices simétricas definidas positivas, donde $\rho(T)$ acota $\|T\|$, esto conduce a:

$$\|e^{(k)}\| \leq \rho(T) \|e^{(k)}\| + \|\delta^{(k)}\|,$$

y despejando:

$$\|e^{(k)}\| \leq \frac{1}{1 - \rho(T)} \|\delta^{(k)}\|. \quad (3.9)$$

La cota (3.9) muestra que el incremento $\delta^{(k)}$ puede usarse como medida indirecta del error, pero solo cuando $\rho(T) \ll 1$. Si el radio espectral es cercano a 1, el factor $1/(1 - \rho(T))$ amplifica el incremento y este deja de ser una estimación confiable del error.

3.4.2. Criterios prácticos de parada

En vista del análisis anterior, los criterios más habituales son los siguientes:

1) **Diferencia absoluta entre iteraciones:**

$$\|x^{(k)} - x^{(k-1)}\| \leq \text{Tol}_1.$$

La tolerancia Tol_1 depende del significado físico de la variable x y de sus unidades, lo que dificulta establecer un valor universal.

2) **Diferencia relativa entre iteraciones:**

$$\frac{\|x^{(k)} - x^{(k-1)}\|}{\|x^{(k)}\|} \leq \text{Tol}_2.$$

Al normalizar por la norma de la iteración actual, la tolerancia Tol_2 es adimensional e independiente de las unidades, lo que permite especificar valores como 10^{-4} o 10^{-6} con significado universal.

3) **Residuo relativo:**

$$\|r^{(k)}\| \leq \text{Tol}_3 \|b\|.$$

Dado que el residuo $r^{(k)} = b - Ax^{(k)}$ tiene las mismas unidades que b , normalizarlo por $\|b\|$ produce también un criterio adimensional. Este criterio es especialmente útil cuando se desea controlar directamente cuán bien se satisface el sistema.

En la práctica, los criterios 2) y 3) son preferibles al 1) por su independencia de las unidades. Sin embargo, ninguno de los tres garantiza por sí solo que el error verdadero $e^{(k)}$ sea pequeño: según la cota (3.9), la relación entre el incremento y el error depende de $\rho(T)$, y la relación entre el residuo y el error depende del condicionamiento de A mediante (3.8).